# test_items2/beauty 임베딩 모델 비교

작성일: 2026-10-19

목적: 기존 test_items/beauty 비교와 같은 방식으로 test_items2/beauty 에서 BM25 와 임베딩 검색 결합 결과를 비교

## 요약

- 평가 대상은 test_items2 의 beauty 범주입니다. 원본의 별도 활성 run 에 이미 만들어진 96 토큰 청크를 그대로 사용했습니다. 모델 간 검색 비교에서 청킹 차이가 섞이지 않도록 새로 쪼개지는 않았습니다.
- BM25 단독과 현재 MiniLM 구성을 기준선으로 두고, 앞서 비교한 세 대안 E5, BGE-M3, Qwen3 를 같은 청크와 질의로 평가했습니다. 대안들은 BM25 를 대체한 것이 아니라 BM25 Top 20 과 dense 벡터 Top 20 을 상품 단위 RRF(k=60)로 결합했습니다.
- 현재 수치에서 가장 나은 모델을 확정하기는 어렵습니다. 긍정 질의가 10 개이고 기대 상품 목록은 상품명·유형 규칙으로 만든 임시 라벨이며, 사람의 관련성 검수가 없습니다. Hit@5 가 높아도 확정 정확도로 볼 수 없습니다.
- 전체 질의별 첫 정답 순위와 측정 조건은 아래 표에 기록했습니다. 모델 임베딩 벡터는 임시 디렉터리에만 생성했고 DB 에는 쓰지 않았습니다.

## 데이터와 청킹

| 항목 | 값 |
|---|---|
| 데이터 버전 | test_items2:v6.1-review-refined:sha256=94681a28271ca9b1:products=1500:reviews=46100 |
| 범주·규모 | beauty, 상품 781 개, 리뷰 34,545 개, 청크 78,595 개 |
| 활성 run | e925490f-4f34-4c03-9248-eb9ebdfcde48 |
| 청커 | source-evidence-token-v2:max_tokens=96 |
| 기존 벡터 | sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2, 384 차원 |
| 평가 범위 | 긍정 질의 10 개, 범위 밖 질의 2 개, 총 12 개 |
| 상품 결과 | 질의별 Top 5 |

이 run 은 전체 test_items2 후보 데이터 1,500 개 상품·46,100 개 리뷰 가운데 beauty 만 평가했습니다. beauty 리뷰 34,545 개 중 32,207 개는 실수집 리뷰, 2,338 개는 합성 리뷰입니다. 데이터 README 에서 v6.1 review-refined 는 검토 후보로 표시되어 있어,

데이터 자체의 적합성에 대한 사람 검수도 별도 필요합니다. 이 프로필은 현재 서비스 API 에 연결되지 않았습니다.

청크는 별도 run 에서 이미 만들어져 있고 DB 에 저장된 기존 MiniLM 벡터와 BM25 결과를 확인할 수 있었습니다. 그래서 청킹을 중복 생성하지 않았습니다. 새로 청킹하면 임베딩 모델 외에 청크 분할 차이까지 결과에 영향을 주어, 이번 모델 비교의 조건을 흐리게 합니다.

## 질의와 평가 라벨

기존 테스트와 맞추려고 `beauty` 의 10 개 긍정 질의를 유지하되, `test_items2` 에 같은 컨실러 정답 상품이 없어 `트러블 진정 세럼 추천`으로 대체했습니다. 기대 상품 수는 범주나 검색어 표현을 상품 유형·상품명 규칙으로 골라 생성했습니다. 사람 검수 정답이 아니며, 서로 겹치는 기대 상품이 있을 수 있습니다.

| 질의 | 기대 상품 수 |
|---|---|
| 트러블 진정 세럼 추천 | 12 |
| 블러셔 추천 | 8 |
| 아이라이너 추천 | 5 |
| 눈썹용 브로우 추천 | 5 |
| 입술 보습 립밤 추천 | 3 |
| 건조할 때 바르는 수분 크림 추천 | 24 |
| 트러블 여드름 피부 토너패드 추천 | 4 |
| SPF 50 비비크림 추천 | 1 |
| 우르오스 올인원 스킨밀크 200ml | 1 |
| 민감하고 건조한 피부 장벽 보습 크림 | 19 |
| 게임용 기계식 키보드 적축 추천 | OOD |
| 세탁세제 추천 | OOD |

범위 밖 질의는 `게임용 기계식 키보드 적축 추천`, `세탁세제 추천`입니다. 범위 밖 질의에서는 임베딩 모델이 상품을 반환하지 않게 하는 임계값이나 거절 동작을 설정하지 않았습니다.

## 비교 방법

- 질의마다 활성 run 의 `beauty` 데이터에서 가져온 BM25 Top 20 을 고정했습니다. 데이터베이스는 읽기만 했습니다.
- E5, BGE-M3, Qwen3 는 같은 78,595 개 청크를 각각 임베딩하고 dense 벡터 Top 20 을 계산했습니다. 기존 MiniLM 결과에는 DB 에 저장된 384 차원 벡터를 재사용했습니다.
- 각 검색 결과에서 상품별 첫 청크 순위를 취한 뒤 BM25 와 dense 결과를 RRF(`k=60`)로 결합했습니다. BM25 단독은 저장된 BM25 청크 순위에서 상품별 첫 순위를 취해 Top 5 를 냈습니다.
- 모든 임베딩 모델의 최대 입력 길이는 128 토큰이었습니다. 저장 청크 상한은 96 토큰입니다. E5 문서 입력은 `passage:`, 질의는 `query:` 접두어를 사용했습니다. Qwen3 질의에는 검색 지시문 템플릿을 붙였습니다.
- 이 평가에는 별도의 리랭커나 답변 생성 모델이 없습니다. BGE-M3 는 dense 벡터만 썼고 sparse·multi-vector 기능은 비교하지 않았습니다.

## 검색 품질

| 구성 | 차원 | Hit@1 | Hit@5 | Macro Recall@5 | Macro MRR@5 | Macro Precision@5 | OOD 반환 |
|---|---|---|---|---|---|---|---|
| BM25 단독 | — | 60% (6/10) | 100% (10/10) | 0.540 | 0.767 | 0.400 | 2/2 |
| BM25 + MiniLM-L12-v2 | 384 | 40% (4/10) | 100% (10/10) | 0.451 | 0.595 | 0.360 | 2/2 |
| BM25 + multilingual-e5-large | 1,024 | 80% (8/10) | 100% (10/10) | 0.620 | 0.883 | 0.580 | 2/2 |
| BM25 + BGE-M3 dense | 1,024 | 80% (8/10) | 100% (10/10) | 0.627 | 0.900 | 0.580 | 2/2 |
| BM25 + Qwen3-Embedding-0.6B | 1,024 | 80% (8/10) | 100% (10/10) | 0.608 | 0.883 | 0.580 | 2/2 |

`Hit@1` 과 `Hit@5` 는 각각 첫 상품 또는 상위 5 개 상품 안에 기대 상품이 하나 이상 나온 긍정 질의 비율입니다. 긍정 질의가 10 개라 한 질의의 차이가 10%p 입니다. `Macro Recall@5` 는 기대 상품 중 Top 5 에서 찾은 비율을 질의별 계산 후 평균한 값입니다. `Macro MRR@5` 는 첫 기대 상품 순위를, `Macro Precision@5` 는 Top 5 중 기대 상품 비율을 질의별로 계산해 평균합니다.

검색 결과는 최대 5 개이며, 상품 중복을 합친 뒤 후보가 5 개보다 적은 질의도 있습니다. 긍정 질의 10 개 중 그런 경우는 BM25 6 개, MiniLM 0 개, E5 1 개, BGE-M3 1 개, Qwen3 2 개였습니다. `Macro Precision@5` 는 후보가 적더라도 분모를 5 로 계산했습니다.

아래 표의 순위는 각 구성의 Top 5 안에서 처음 나온 기대 상품의 순위입니다. —는 기대 상품을 Top 5 에서 찾지 못했다는 뜻입니다.

OOD 는 해당 질의에서 상품이 반환됐는지를 표시합니다.

| 질의 | 기대 수 | BM25 | MiniLM | E5 | BGE-M3 | Qwen3 |
|---|---|---|---|---|---|---|
| 트러블 진정 세럼 추천 | 12 | 1 | 1 | 1 | 1 | 1 |
| 블러셔 추천 | 8 | 1 | 2 | 1 | 1 | 1 |
| 아이라이너 추천 | 5 | 1 | 1 | 1 | 1 | 1 |
| 눈썹용 브로우 추천 | 5 | 1 | 1 | 1 | 1 | 1 |
| 입술 보습 립밤 추천 | 3 | 2 | 4 | 1 | 1 | 1 |
| 건조할 때 바르는 수분 크림 추천 | 24 | 3 | 5 | 3 | 1 | 1 |
| 트러블 여드름 피부 토너패드 추천 | 4 | 3 | 4 | 1 | 1 | 1 |
| SPF 50 비비크림 추천 | 1 | 1 | 4 | 1 | 2 | 3 |
| 우르오스 올인원 스킨밀크 200ml | 1 | 1 | 1 | 1 | 1 | 1 |
| 민감하고 건조한 피부 장벽 보습 크림 | 19 | 2 | 2 | 2 | 2 | 2 |
| 게임용 기계식 키보드 적축 추천 | 범위 밖 | 상품 반환 | 상품 반환 | 상품 반환 | 상품 반환 | 상품 반환 |
| 세탁세제 추천 | 범위 밖 | 상품 반환 | 상품 반환 | 상품 반환 | 상품 반환 | 상품 반환 |

이번 결과는 카탈로그의 실제 상품명·유형 라벨로 만든 작은 탐색 평가입니다. 일반적인 상품군 질의는 관련 상품이 다수이므로 정답 목록 자체가 결과에 큰 영향을 줍니다. 자동 라벨이 적절한 추천 여부까지 판정하지 않으며, 10 개 질의에서 나온 모델 순위를 전체 서비스 정확도로 일반화하면 안 됩니다. OOD 2 개가 모든 구성에서 상품을 반환했으므로, 범위 밖 검색 제어도 별도 평가해야 합니다.

## 로컬 CPU 비용

문서 임베딩 시간은 78,595 개 청크의 벡터를 생성하는 데 걸린 시간이며, 모델 로드 시간·DB 저장·pgvector 인덱스 작성은 포함하지 않습니다. MiniLM 행은 DB 에 저장된 벡터를 재사용해 이번 작업의 전체 재임베딩 시간은 측정하지 않았습니다. 질의 임베딩과 exact dense 점수 계산 p50/p95 는 12 개 질의에서 구한 값입니다.

| 구성 | 문서 임베딩 시간 | 처리량 | 질의 임베딩 p50 / p95 | 메모리 내 dense 점수 p50 / p95 |
|---|---|---|---|---|
| BM25 단독 | 해당 없음 | 해당 없음 | DB BM25 시간 미계측 | 서비스 DB 측정 미계측 |

| 구성 | 문서 임베딩 시간 | 처리량 | 질의 임베딩 p50 / p95 | 메모리 내 dense 점수 p50 / p95 |
|---|---|---|---|---|
| BM25 + MiniLM-L12-v2 | 기존 벡터 재사용 | 이번 평가에서 재임베딩 안 함 | 4.2 / 12.4 ms | 8.2 / 9.5 ms |
| BM25 + multilingual-e5-large | 90.3 분 (5,420.8 초) | 14.50 청크/초 | 21.6 / 27.2 ms | 14.1 / 24.9 ms |
| BM25 + BGE-M3 dense | 48.9 분 (2,931.5 초) | 26.81 청크/초 | 135.2 / 143.9 ms | 8.0 / 64.9 ms |
| BM25 + Qwen3-Embedding-0.6B | 173.2 분 (10,394.0 초) | 7.56 청크/초 | 53.0 / 58.9 ms | 13.9 / 59.3 ms |

MiniLM · E5 · Qwen3 는 FastEmbed 0.9.0 ONNX CPU 경로(8 threads)를 썼고, BGE-M3 는 Transformers CPU `bfloat16` 경로(8 threads)를 썼습니다. 로컬 문서 임베딩 시간은 이 실행 환경의 처리량 지표이지, GPU 나 운영 서버 성능을 대표하지 않습니다. Dense 점수 검색은 NumPy 메모리 행렬에서 exact cosine 으로 계산했으며, 표의 값은 DB 벡터 인덱스나 API 지연 시간이 아닙니다. BM25 조회의 서비스 지연은 별도로 계측하지 않았습니다.

## 결과 해석

BM25 와 임베딩을 결합한 각 행은 동일한 고정 BM25 후보를 포함합니다. 따라서 해당 행의 변화는 임베딩 후보가 RRF 에 더해져 상품 순위를 움직인 효과를 반영합니다. Hit@5 와 OOD 반환 수치만으로 운영 승자를 정할 수 없고, 정답 라벨을 검수한 더 큰 질의 세트에서 결과를 반복 확인해야 합니다.

운영 후보를 좁힌다면 E5 와 BGE-M3 를 우선 비교하는 편이 합리적입니다. 둘 다 이번 검색 지표가 BM25 또는 MiniLM 기준선보다 나은지 질의별 표로 확인할 수 있고, E5 는 질의 임베딩 시간이 더 짧은 반면 BGE-M3 는 문서 임베딩 시간이 이 환경에서 더 짧았습니다. 둘의 실제 품질 차이는 임시 라벨 규모에서 확정할 수 없습니다. Qwen3 결과는 같은 형식으로 표에 포함했으며, 별도의 검색 장점이 있는지 이 질의별 순위와 측정 비용을 함께 봐야 합니다.

## DB 와 코드 영향

이번 평가는 `5432/toss_rag` 에서 해당 run 의 청크 · BM25 순위 · MiniLM 벡터를 읽고, 대안 임베딩과 최종 RRF 결과를 오프라인으로 계산했습니다. DB 쓰기, DDL, 인덱스 변경은 하지 않았습니다. E5 · BGE-M3 · Qwen3 문서 벡터는 `/tmp` 아래에만 저장했습니다.

현재 저장된 벡터는 384 차원 MiniLM 입니다. 1,024 차원 모델을 서비스에 적용하면 전체 청크를 선택 모델로 다시 임베딩하고, 새 차원의 DB 컬럼/테이블 및 인덱스와 코드의 차원 검사를 함께 준비해야 합니다. 기존 384 차원 벡터와 1,024 차원 벡터를 같은 검색 공간에 섞을 수 없습니다. 이 보고서는 DB 마이그레이션이나 운영 API 적용 결과가 아닙니다.

## 결론과 다음 단계

이번 `test_items2/beauty` 비교는 이미 존재하는 96 토큰 청크를 이용해 BM25 단독, MiniLM 기준선, 세 대안 임베딩을 같은 검색 흐름으로 평가했습니다. 청킹을 다시 하지 않은 것은 데이터가 이미 별도 run 으로 청킹되어 있었고, 모델 차이만 비교하기 위해서입니다.

결과는 라벨 생성 규칙과 10 개 긍정 질의에 민감합니다. 먼저 사람이 기대 상품과 OOD 질의를 검수한 뒤 재평가하고, 그 결과를 보고 임베딩 후보를 선택하는 것이 타당합니다. 이전 데이터셋 결과는 기존 `test_items/beauty` 비교 문서에 있습니다.